

Relatório Técnico — Tech Challenge Fase 1

Sistema de Apoio ao Diagnóstico de Câncer de Mama

1. Introdução e definição do problema

Redes de saúde especializadas no atendimento à mulher lidam com um volume crescente de pacientes e com a necessidade de identificar rapidamente situações de risco. Atrasos ou erros na triagem de exames podem ter consequências graves.

Este projeto constrói a base de um sistema de **Machine Learning** capaz de classificar tumores de mama como **malignos** ou **benignos** a partir de medidas extraídas de exames de imagem. O objetivo é oferecer uma **ferramenta de apoio à decisão** que acelere a triagem e destaque casos de risco — sempre preservando o julgamento final do médico.

O problema é de **classificação binária supervisionada**: a partir de 30 medidas numéricas, prever uma de duas classes (maligno ou benigno).

2. A base de dados

Foi utilizada a base **Breast Cancer Wisconsin (Diagnostic)**, pública e amplamente validada na literatura, disponível na biblioteca scikit-learn.

- **569 pacientes** (amostras de tumores)
- **30 medidas** por paciente, derivadas da imagem digitalizada de uma punção aspirativa por agulha fina (PAAF). As medidas descrevem o núcleo das células (raio, textura, perímetro, área, suavidade, compacidade, concavidade, pontos côncavos, simetria e dimensão fractal), cada uma em três versões: média (*mean*), erro padrão (*error*) e pior caso (*worst*).
- **Alvo:** 0 = Maligno · 1 = Benigno

A escolha desta base se justifica por ser confiável, bem documentada e diretamente alinhada à tarefa principal sugerida no desafio (diagnóstico de câncer de mama).

3. Análise exploratória dos dados (EDA)

3.1 Distribuição das classes

A base contém **212 casos malignos (37,3%)** e **357 benignos (62,7%)**, caracterizando um **desbalanceamento moderado**.

Esse desbalanceamento tem uma implicação crítica: um modelo ingênuo que classificasse todas as pacientes como "benigno" alcançaria 62,7% de acurácia, mas deixaria passar **100% dos cânceres**. Essa constatação norteou toda a escolha de métricas de avaliação (Seção 6).

3.2 Qualidade dos dados

A verificação de valores ausentes não identificou nenhum dado faltante (0 ocorrências). Portanto, **não foi necessária imputação**. A ausência de inconsistências permitiu focar o pré-processamento na preparação para a modelagem.

3.3 Padrões identificados

A comparação das médias por classe revelou um padrão consistente: **tumores malignos apresentam valores maiores em praticamente todas as medidas**, em especial nas relacionadas a tamanho (raio, perímetro, área) e à irregularidade do contorno (concavidade e pontos côncavos).

Medida	Maligno (média)	Benigno (média)
mean radius	17,46	12,15
mean perimeter	115,37	78,08
mean area	978,38	462,79
mean concavity	0,16	0,05
mean concave points	0,09	0,03
worst area	1422,29	558,90

Os histogramas confirmaram visualmente esse padrão: as medidas `mean concave points` e `mean concavity` mostraram a melhor separação entre as classes, com sobreposição mínima — indicando alto poder discriminativo.

3.4 Análise de correlação

A correlação entre cada medida e o diagnóstico confirmou que as medidas de **tamanho** e de **pontos côncavos** são as mais associadas à malignidade. Em contraste, medidas como `fractal dimension error`, `texture error` e `symmetry error` apresentaram correlação próxima de zero.

A análise de correlação entre as próprias medidas revelou forte **multicolinearidade** no bloco de tamanho: `mean radius`, `mean perimeter` e `mean area` têm correlação $\approx 0,99$ entre si — esperado, pois são formas geométricas de medir a mesma característica. Já a concavidade mostrou-se relativamente independente do tamanho, carregando informação complementar. Essa observação ajuda a justificar o teste de múltiplos modelos, já que a multicolinearidade afeta modelos lineares de forma diferente dos baseados em árvores.

4. Pré-processamento

O pipeline de pré-processamento seguiu três etapas:

1. **Separação de features (X) e alvo (y):** as 30 medidas como variáveis preditoras e o diagnóstico como variável-alvo.
2. **Divisão treino/teste:** separação estratificada de 80% para treino (455 pacientes) e 20% para teste (114 pacientes). A estratificação (`stratify=y`) preservou a proporção 37/63 nos dois conjuntos, e a semente fixa (`random_state=42`) garante reprodutibilidade.
3. **Padronização:** as medidas possuem escalas muito distintas (área na casa dos milhares; suavidade na casa dos centésimos). Aplicou-se `StandardScaler` para colocar todas as medidas na mesma escala (média 0, desvio 1).

Cuidado contra data leakage: o padronizador foi ajustado (fit) **apenas** nos dados de treino e depois aplicado (transform) no teste. Isso evita que informações do conjunto de teste influenciem o treinamento, garantindo uma avaliação honesta.

5. Modelagem

Foram treinados e comparados **três modelos** de naturezas diferentes:

- **Regressão Logística** — modelo linear, interpretável, eficaz quando a separação entre classes é relativamente linear.
- **Árvore de Decisão** — modelo baseado em regras, altamente interpretável (`max_depth=4` para evitar sobreajuste).
- **Random Forest** — conjunto (*ensemble*) de 200 árvores que votam, robusto e excelente para estimar a importância das variáveis.

A diversidade de abordagens permite uma comparação justa e fundamenta a escolha do modelo final com base em evidência.

6. Avaliação

6.1 Escolha da métrica

Em um problema de diagnóstico de câncer, **os dois tipos de erro não têm o mesmo peso**:

- **Falso negativo** (classificar um tumor maligno como benigno): gravíssimo — a paciente deixa de receber tratamento.
- **Falso positivo** (classificar um tumor benigno como maligno): gera ansiedade e exames adicionais, mas é corrigível por exames subsequentes.

Por isso, embora a acurácia seja reportada, a **métrica prioritária é o recall da classe maligna** (sensibilidade): a proporção dos cânceres reais que o modelo consegue detectar. Minimizar falsos negativos é o objetivo central de um sistema de triagem.

6.2 Resultados

Modelo	Acurácia	Recall (maligno)	Precisão (maligno)	F1 (maligno)
Regressão Logística	98,2%	97,6%	97,6%	97,6%
Árvore de Decisão	93,9%	92,9%	90,7%	91,8%
Random Forest	95,6%	92,9%	95,1%	94,0%

A **Regressão Logística** apresentou o melhor desempenho em todas as métricas. Sua matriz de confusão revelou apenas **1 falso negativo** e **1 falso positivo** entre as 114 pacientes do teste.

6.3 Discussão: por que o modelo mais simples venceu

Um resultado contraintuitivo, mas valioso: o Random Forest, mais complexo, **não** superou a Regressão Logística. Isso ocorre porque a relação entre as medidas e o diagnóstico nesta base é bem comportada e aproximadamente linear (como evidenciado pela boa separação das classes na EDA). Nesse cenário, um modelo linear captura o padrão de forma eficaz, sem a complexidade adicional do *ensemble*. O resultado reforça um princípio importante: **o modelo mais simples que resolve bem o problema é, em geral, a melhor escolha** (princípio da parcimônia).

7. Explicabilidade

Para que um sistema de IA seja confiável em medicina, suas decisões precisam ser auditáveis — não uma "caixa-preta".

7.1 Feature importance (Random Forest)

As cinco medidas mais influentes foram: `worst_perimeter`, `worst_area`, `worst_concave_points`, `mean_concave_points` e `worst_radius`. Ou seja, **tamanho e irregularidade do contorno** — exatamente os padrões identificados na análise exploratória.

7.2 Análise SHAP

A análise SHAP confirmou, paciente a paciente, a coerência do modelo: **valores altos** de tamanho e de pontos côncavos empurram a decisão para "maligno", enquanto **valores baixos** empurram para "benigno". Esse comportamento é clinicamente coerente e aumenta a confiabilidade do modelo como ferramenta de apoio.

7.3 Convergência das evidências

O mesmo conjunto de variáveis (tamanho e pontos côncavos) emergiu como mais relevante por **cinco caminhos independentes**: comparação de médias, histogramas, correlação, primeira divisão da árvore de decisão e importância no Random Forest. Essa convergência confere robustez à conclusão de que essas características são os indicadores mais confiáveis de malignidade nesta base.

8. Conclusão e considerações sobre uso prático

O modelo final (Regressão Logística) atinge 98,2% de acurácia e 97,6% de recall na classe maligna, demonstrando viabilidade técnica como ferramenta de triagem.

O modelo pode ser usado na prática? Sim, **como apoio à decisão** — não como substituto do médico. Pontos a considerar:

- Mesmo com 97,6% de recall, o modelo ainda erra. Em saúde, cada erro tem impacto humano real, o que torna a supervisão médica indispensável.
- O modelo identifica **correlações**, não causas. Ele aponta quais medidas acompanham o diagnóstico, sem explicar mecanismos biológicos.
- O desempenho depende da qualidade dos dados de entrada. Uma base limpa e equilibrada favoreceu os resultados; em produção, dados ruidosos exigiriam validação contínua.

Uso recomendado: triagem inicial e priorização de casos, sinalizando exames de maior risco para atenção médica imediata, com o diagnóstico final sempre validado por um profissional.

Trabalhos futuros

- Validação com dados de outras instituições para testar generalização.
- Extensão com Visão Computacional (CNN) para análise direta de mamografias.
- Interface interativa para uso por profissionais de saúde.

9. Reprodutibilidade

Todo o desenvolvimento está no notebook `notebooks/tech_challenge.ipynb`, executável de ponta a ponta (**Run → Run All Cells**). As dependências estão em `requirements.txt` e o modelo treinado em `src/`.